

# Analisis Konsentrasi dan Laju Ekspirasi Zat Radon pada Material Bangunan serta Pemodelan Prediktif Menggunakan *Machine Learning*

Raden Muhammad Imadudin<sup>1</sup>, Adi Wijayanto<sup>2</sup>, Akida Mulyaningtyas<sup>1</sup>, Hamid Abdullah<sup>1</sup>

<sup>1</sup>Teknik Kimia, Fakultas Teknik, Universitas Muhammadiyah Surakarta, Jawa Tengah, Indonesia

<sup>2</sup>Instalasi Pengolahan Limbah Radioaktif, Direktorat Pengelolaan Fasilitas Ketenaganukliran, Badan Riset dan Inovasi Nasional, Serpong, Jawa Barat, Indonesia

---

## Abstrak

Radon ( $^{222}\text{Rn}$ ) merupakan gas radioaktif alami yang dapat terlepas dari material bangunan dan berpotensi membahayakan kesehatan manusia apabila terakumulasi dalam ruang tertutup. Penelitian ini bertujuan untuk mengkaji variasi konsentrasi Radon dari empat jenis material bangunan umum, serta mengeksplorasi pendekatan *machine learning* dalam membangun model prediksi laju ekspirasi Radon berbasis parameter fisik dan geografis material. Sampel diambil dari tujuh wilayah di Provinsi Jawa Tengah dan Jawa Timur, Indonesia. Pengukuran dilakukan menggunakan detektor RAD7, *alpha-beta counter*, serta perhitungan *bulk density* untuk mengetahui konsentrasi Radon, aktivitas gross alfa-beta, bulk density, dan temperatur sampel. Data dianalisis menggunakan statistik deskriptif, korelasi Pearson, serta dua algoritma machine learning: Random Forest dan Gradient Boosting Machine.

Hasil penelitian menunjukkan bahwa seluruh sampel material bangunan dari wilayah Solo dan sekitarnya memiliki konsentrasi radon yang berada jauh di bawah ambang batas aman IAEA ( $300 \text{ Bq m}^{-3}$ ), meskipun terdapat variasi signifikan antar jenis dan lokasi material. Evaluasi model machine learning menunjukkan bahwa variabel gross alpha paling berpengaruh dalam prediksi laju eksalasi dengan model GBM menghasilkan performa terbaik ( $R^2 = 0,473$ ; RMSE = 0,138; MAE = 0,006), menandakan bahwa pendekatan ini efektif dalam menangkap hubungan kompleks antar variabel. Secara keseluruhan, kombinasi analisis fisik, radioaktif, dan prediktif mampu memberikan gambaran yang lebih holistik dalam menilai potensi risiko paparan radon dari material bangunan lokal.

**Kata Kunci:** Radon; Material Bangunan; Bulk Density; Alpha-Beta; Machine Learning; Random Forest; Gradient Boosting

---

## 1. Pendahuluan

Radon ( $^{222}\text{Rn}$ ) adalah gas radioaktif yang dihasilkan oleh peluruhan radioaktif radium ( $^{226}\text{Ra}$ ). Menghirup Radon dan turunannya yang berumur pendek ( $^{218}\text{Po}$ ,  $^{214}\text{Pb}$ ,  $^{214}\text{Bi}$ , dan  $^{214}\text{Po}$ ) di dalam ruangan merupakan salah satu risiko radiasi bagi masyarakat. Studi epidemiologi terkini menyiratkan bahwa ada hubungan antara paparan Radon di dalam ruangan dan resiko kanker

---

\*Corresponding author. E-mail address: [author4@email.com](mailto:author4@email.com)

Received: xx xxxxx 20xx, Accepted: xx xxxxx 20xx and available online XX July 2022

<https://doi.org/10.1016/j.compeleceng.2021.107553>

paru-paru. Paparan radiasi penganon alami di masyarakat sebagian besar disebabkan oleh Radon, sekitar 50% dari paparan alami terhadap manusia [1].

Radon tidak berwarna, tidak berbau, dan tidak berasa hanya dapat dideteksi dengan peralatan khusus. Paparan jangka panjang terhadap kadar Radon yang tinggi menimbulkan risiko kesehatan yang signifikan, termasuk kanker paru-paru. Memahami faktor-faktor yang memengaruhi laju pernafasan permukaan Radon sangat penting untuk mengelola paparan Radon dan mengurangi dampaknya terhadap kesehatan masyarakat [2].

Organisasi Kesehatan Dunia (WHO) mendefinisikan radon sebagai gas inert yang dilepaskan selama peluruhan uranium ( $^{238}\text{U}$ ) yang ada di mana-mana baik di lingkungan dalam maupun luar ruangan [3]. Badan Tenaga Atom Internasional, sesuai dengan Seri Standar Keselamatan IAEA merekomendasikan agar konsentrasi radon tidak boleh melebihi 300 dan 1000 Bq m $^{-3}$  untuk masyarakat umum dan pekerja [4].

Sebagian besar sumber Radon di sekitar kita berasal dari dinding dan langit-langit bangunan yang terbuat dari bahan yang mengandung radium. Secara umum, dapat dikatakan bahwa Radon dari tanah banyak terdapat di lantai bawah suatu bangunan, sedangkan Radon dari lantai lebih atas berasal dari bahan bangunan itu sendiri [5].

Sejumlah penelitian sebelumnya telah menunjukkan bahwa berbagai jenis bahan bangunan, seperti bata merah, semen, pasir, maupun material ringan seperti hebel, mengandung unsur radioaktif alami yang dapat menjadi sumber eksalasi Radon. Misalnya, studi oleh Bao et al. [6] mengeksplorasi prediksi eksalasi Radon dari sampel tambang tembaga menggunakan pendekatan *machine learning*, sementara Al-Shboul et al. [2] meneliti interaksi antara karakteristik tanah dan tingkat eksalasi Radon dengan *multivariate analysis*. Namun, kajian yang secara khusus menghubungkan sifat fisik material seperti *bulk density* dan aktivitas alfa-beta terhadap laju ekspirasi Radon di Indonesia masih sangat terbatas.

Penelitian ini dilakukan untuk menjawab kebutuhan data dan pemahaman lokal terkait potensi eksalasi Radon dari material bangunan yang umum digunakan di Indonesia. Melalui pendekatan eksperimen dan eksplorasi prediktif berbasis *machine learning*, penelitian ini bertujuan mengisi celah dalam literatur sekaligus menawarkan metode penilaian alternatif terhadap potensi bahaya radiasi dari material konstruksi.

Penelitian ini mengukur konsentrasi Radon dari berbagai jenis material bangunan yang diambil dari tujuh wilayah di Indonesia, menggunakan detektor RAD7 dan *alpha-beta counter*. Selain itu, data *bulk density*, aktivitas *gross* alfa dan *gross* beta, serta lokasi sampel juga dihimpun sebagai variabel analisis. Variabel alfa-beta digunakan berdasarkan penelitian Ferreira et al. yang menunjukkan bahwa dalam rantai peluruhannya,  $^{222}\text{Rn}$  melepaskan partikel alfa dan kemudian menghasilkan radionuklida turunan yang melepaskan partikel beta [7]. Sedangkan variabel *bulk density* digunakan berdasarkan studi Ye et al. yang mana diketahui bahwa difusi yang dipengaruhi oleh *density* [8] sering digunakan untuk menggambarkan kemampuan radon untuk bermigrasi di media berpori dan nilainya mempengaruhi laju ekspirasi radon dari permukaan media emanasi berpori [9].

Korelasi antar variabel dianalisis menggunakan metode Pearson, dan pemodelan prediktif dilakukan menggunakan algoritma Random Forest dan Gradient Boosting Machine untuk mengevaluasi kemampuan sistem memprediksi laju ekspirasi Radon dari parameter fisik dan radiologis material.

Hasil awal menunjukkan bahwa variabel *gross* beta memiliki hubungan negatif yang cukup kuat terhadap laju ekspirasi Radon, sedangkan fitur lain seperti jenis material dan *bulk density* juga berkontribusi signifikan dalam prediksi model.

Kebaruan dari penelitian ini terletak pada integrasi data eksperimen lokal dengan pendekatan *machine learning* yang mampu mengidentifikasi variabel penting secara nonlinier, serta pada fokusnya terhadap karakteristik material bangunan yang jarang diidentifikasi. Hasil penelitian diharapkan dapat menjadi pijakan awal dalam pengembangan sistem evaluasi risiko berbasis data terhadap material konstruksi, terutama dalam konteks keamanan radiasi di lingkungan tempat tinggal.

## 2. Metode

Penelitian ini dilakukan untuk mengukur konsentrasi Radon dari berbagai material bangunan dan membangun model prediksi laju eksplorasi Radon berdasarkan fitur-fitur fisik dan geografis. Penelitian ini terdiri dari dua bagian utama: eksperimen lapangan dan laboratorium untuk pengambilan data, serta analisis statistik dan pemodelan *machine learning* untuk eksplorasi prediktif. Ilustrasi pada gambar 1

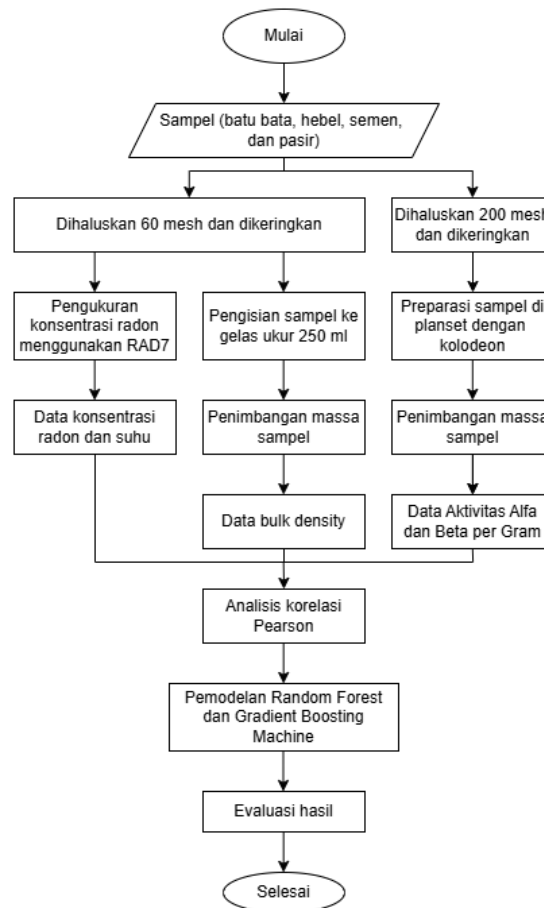


Figure 1. Diagram alir penelitian.

### 2.1 Lokasi dan Sampel Penelitian

Sebanyak 28 sampel material bangunan dikumpulkan dari tujuh wilayah di Provinsi Jawa Tengah, yaitu: Surakarta (SLO), Sukoharjo (SKH), Klaten (KLT), Boyolali (BYL), Karanganyar (KRA), Magetan (MGT), dan Madiun (MDN). Wilayah ini dipilih karena mewakili daerah dengan aktivitas pembangunan tinggi dan variasi sumber bahan bangunan lokal. Secara geografis, wilayah ini berada di zona iklim tropis dengan suhu harian rata-rata 25–32°C dan kelembapan relatif tinggi. Secara geologis, daerah ini didominasi oleh batuan vulkanik muda yang dapat berpotensi mengandung uranium dan turunannya sebagai sumber Radon. Jenis material yang diuji terdiri dari: semen, pasir, bata merah, hebel (bata ringan).

### 2.2 Preparasi Sampel dan Teknik Pengukuran

Setiap sampel dikeringkan terlebih dahulu untuk menurunkan kelembapan. Selanjutnya dilakukan dua jenis pengukuran utama:

1. Pengukuran *bulk density*: menggunakan metode gravimetri dengan persamaan:



**Figure 2.** Peta lokasi pengambilan sampel material bangunan di wilayah Jawa Tengah.

$$\rho = \frac{m}{V}$$

di mana  $\rho$  adalah densitas ( $\text{kg m}^{-3}$ ),  $m$  adalah massa sampel (kg), dan  $V$  adalah volume material.

2. Pengukuran aktivitas alfa dan beta: menggunakan *alpha-beta counter* type Ludlum 3030P, dengan metode penghitungan *count per minute* (cpm). Sampel digerus dan disaring hingga lolos mesh 200, lalu dimasukkan dalam wadah plat *planchet*, dan dilakukan pembacaan.

3. Pengukuran konsentrasi Radon: menggunakan *RAD7 detector* (DurrIDGE Company). Sampel diletakkan dalam tabung tertutup, dihubungkan dengan detektor melalui filter karbon dan pompa. Deteksi dilakukan selama 20 x 10 menit dalam mode *sniff*, dan hasil dibaca dalam satuan  $\text{Bq m}^{-3}$ .

### 2.3 Analisis Statistik

Data yang diperoleh dianalisis menggunakan:

1. Statistik deskriptif (rata-rata, minimum, maksimum, deviasi standar): digunakan untuk menggambarkan sebaran data awal dan memeriksa adanya *outlier* seperti yang dilakukan pada penelitian serupa [10].

2. Korelasi Pearson: digunakan untuk mengukur kekuatan hubungan linier antar variabel, terutama terhadap laju eksplorasi Radon sebagai target. Korelasi Pearson dipilih karena cocok untuk data numerik kontinyu dan telah digunakan luas dalam studi sejenis [2].

Koefisien korelasi Pearson antara dua variabel  $X$  dan  $Y$  didefinisikan sebagai:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

dengan:

- $r$  : koefisien korelasi Pearson
- $x_i, y_i$  : nilai ke- $i$  dari variabel  $X$  dan  $Y$
- $\bar{x}, \bar{y}$  : rata-rata dari  $X$  dan  $Y$
- $n$  : jumlah total observasi

## 2.4 Pemodelan Machine Learning

Model *machine learning* untuk penelitian ini dibuat menggunakan *package* Scikit-learn Python. *Tuning* model dilakukan dengan mengoptimalkan hiperparameter setiap algoritma *machine learning*.

Dua algoritma *machine learning* (Random Forest (RF) dan Gradient Boosting Machine (GBM)). Keduanya mampu menangani fitur numerik dan kategorikal, serta tahan terhadap *noise*. Pemilihan algoritma ini didasarkan pada efektivitasnya seperti dalam penelitian Bao et al. [6] yang menggunakan RF untuk prediksi eksipirasi Radon di area tambang tembaga. GBM diketahui memiliki performa tinggi untuk data tabular dan mendukung interpretabilitas melalui *feature importance* [11].

Validasi model dilakukan menggunakan teknik *k-fold cross-validation* dengan  $k = 5$ , untuk mengurangi bias pada performa model seperti yang dilakukan pada penelitian serupa oleh Alshboul dkk [10]. Validation error dihitung menggunakan rumus:

$$\text{Validation Error} = \frac{1}{5} \sum_{i=1}^5 e_i$$

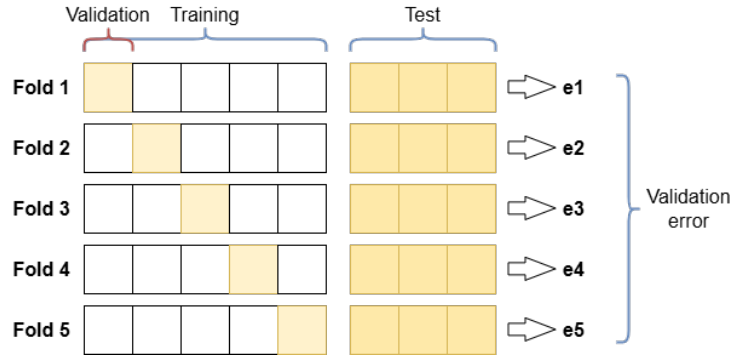


Figure 3. Ilustrasi k-fold cross-validation dengan  $k = 5$

Metrik evaluasi menggunakan Koefisien determinasi ( $R^2$ ) untuk mengukur seberapa besar variasi target dijelaskan oleh model, Root Mean Squared Error (RMSE) untuk mengukur rata-rata kuadrat selisih prediksi dan data aktual, dan Mean Squared Error (MAE) untuk menentukan rata-rata kesalahan absolut antara nilai yang dihasilkan dan nilai aktual seperti yang dilakukan Al-Shboul pada penelitian serupa [10].

*Feature importance* dari kedua model divisualisasikan untuk menentukan kontribusi relatif tiap variabel terhadap *output* prediksi model *machine learning* [11].

## 3. Hasil dan Pembahasan

### 3.1 Perhitungan Konsentrasi Radon

Hasil pengukuran konsentrasi Radon ( $C_{Rn}$ ) dari berbagai jenis sampel bangunan pada tujuh wilayah menunjukkan adanya variasi signifikan pada sampel tertentu, baik antar lokasi maupun antar jenis material. Gambar berikut menampilkan distribusi konsentrasi Radon berdasarkan kombinasi antara jenis bahan bangunan dan lokasi asal sampel.

Terlihat pada gambar 4 bahwa beberapa daerah seperti SKH dan KRA memiliki konsentrasi Radon yang relatif tinggi dibandingkan daerah lain terutama dari sampel SKH-BTA dan KRA-SMN, sedangkan daerah lain seperti SLO relatif lebih rendah jika dilihat dari keseluruhan sampel. Errorbar pada grafik gambaran tentang sebaran atau ketidakpastian nilai rata-rata Radon pada masing-masing kategori. Garis merah pada Konsentrasi Radon ialah garis batas aman untuk konsentrasi Radon dimana nilai  $300 \text{ Bq m}^{-3}$  ditentukan berdasarkan peraturan IAEA General



**Figure 4.** Konsentrasi Radon Berdasarkan Asal Sampel

Safety Standard Part 3 tahun 2014. Dapat dilihat dari grafik bahwa konsentrasi radon pada setiap sampel masih jauh dibawah garis batas yang ditentukan.

### 3.2 Statistik Deskriptif

Sebanyak 28 sampel dianalisis dengan variabel-variabel yang mencakup koordinat lokasi asal sampel, *bulk density*, aktivitas *gross* alfa-beta, temperatur, serta konsentrasi Thoron.

**Table 1.** Statistik deskriptif variabel penelitian

	mean	median	std	min	max
Thoron ( $\text{Bq m}^{-3}$ )	1.86	0.00	5.45	0.00	31.70
Temperatur ( $^{\circ}\text{C}$ )	29.15	29.15	0.73	27.40	31.30
Bulk Density ( $\text{kg m}^{-3}$ )	1.00	0.91	0.25	0.74	1.55
<i>Gross</i> Alfa ( $\text{Bq kg}^{-1}$ )	15.02	12.67	9.76	3.80	45.87
<i>Gross</i> Beta ( $\text{Bq kg}^{-1}$ )	151.36	150.96	56.08	28.50	248.85
Koordinat X	110.95	110.83	0.33	110.60	111.52
Koordinat Y	7.63	7.63	0.06	7.53	7.71

Tabel 1 menyajikan statistik deskriptif dari variabel-variabel yang diamati dalam penelitian ini. Nilai konsentrasi thoron menunjukkan rata-rata sebesar  $1,86 \text{ Bq m}^{-3}$  dengan nilai maksimum mencapai  $31,70 \text{ Bq m}^{-3}$ , sementara nilai median berada pada  $0,00 \text{ Bq m}^{-3}$ , mengindikasikan adanya distribusi data yang sangat skewed dengan banyak sampel tidak terdeteksi (nol). Temperatur lingkungan relatif homogen dengan rata-rata  $29,15^{\circ}\text{C}$  dan simpangan baku sebesar  $0,73$ , yang mencerminkan kondisi pengukuran suhu yang stabil di berbagai sampel.

Bulk density dari material bangunan berkisar antara  $0,74$  hingga  $1,55 \text{ kg m}^{-3}$  dengan rata-rata  $1,00 \text{ kg m}^{-3}$ . Hal ini menunjukkan variasi densitas antar jenis material yang digunakan dalam penelitian. Aktivitas radioaktif alami yang diukur melalui *gross* alfa dan beta menunjukkan bahwa aktivitas beta jauh lebih tinggi (rata-rata  $151,36 \text{ Bq kg}^{-1}$ ) dibandingkan dengan alfa (rata-rata  $15,02 \text{ Bq kg}^{-1}$ ), dengan simpangan baku masing-masing sebesar  $56,08$  dan  $9,76 \text{ Bq kg}^{-1}$ .

Koordinat lokasi pengambilan sampel menunjukkan penyebaran geografis yang cukup luas di wilayah dengan nilai koordinat X antara  $110,60$  dan  $111,52$  sedangkan koordinat Y cukup sempit antara  $7,53$  dan  $7,71$ . Penyebaran ini penting untuk memastikan representasi spasial dalam analisis distribusi radon dan thoron di berbagai titik pengamatan.




Figure 5. Heatmap korelasi Pearson antar variabel.

### 3.3 Korelasi Pearson

Hasil visualisasi korelasi Pearson pada gambar 5 menunjukkan bahwa laju ekspirasi Radon ( $\text{Bq m}^{-2} \text{s}^{-1}$ ) memiliki hubungan negatif paling kuat dengan gross alfa ( $r = -0.13$ ). Ini mengindikasikan bahwa peningkatan aktivitas beta cenderung diikuti oleh penurunan kadar Radon. Sementara itu, korelasi antara Radon dengan variabel lain seperti gross beta, density, dan koordinat lokasi relatif lemah, menunjukkan tidak adanya hubungan linier yang kuat. Korelasi ini menjadi dasar awal untuk mengevaluasi variabel-variabel prediktor dalam pemodelan Radon menggunakan pendekatan *Machine Learning*.

### 3.4 Model Machine Learning dan Feature Importance

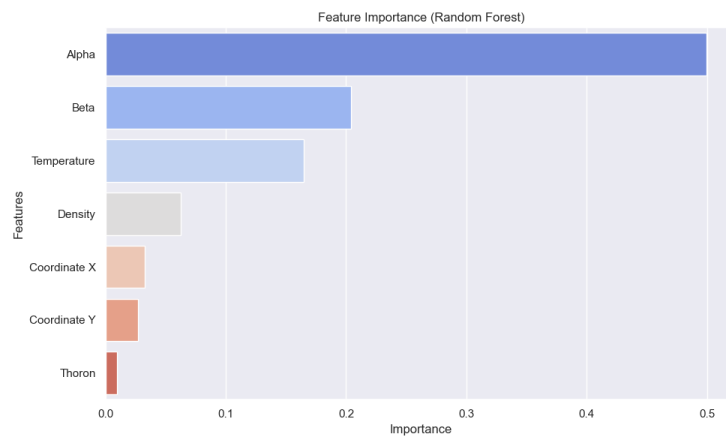



Figure 6. *Feature Importance* model Random Forest.

Pada Gambar 6, model Random Forest menunjukkan bahwa fitur yang paling berkontribusi terhadap prediksi konsentrasi Radon adalah aktivitas alfa. Fitur alfa memiliki skor *importance* sekitar 0.5, beta sekitar 0.2, temperatur sekitar 0.17, sementara fitur lainnya berkontribusi jauh lebih rendah. Hal ini sejalan dengan hasil korelasi Pearson untuk nilai aktivitas alfa. Namun, untuk variabel-variabel lain nilai antara korelasi Pearson dan feature importance tidak memperlihatkan

kesamaan. Hal ini menunjukkan adanya kemungkinan hubungan non-linier atau interaksi antar variabel yang tidak tertangkap oleh korelasi linier, namun berhasil diidentifikasi oleh model *machine learning*.



**Figure 7.** *Feature Importance* model Gradient Boost Machine.

Gambar 7 menunjukkan hasil yang hampir mirip dengan model RF, dengan fitur alfa sebagai prediktor paling dominan. Skor *importance* fitur alfa pada model GBM mencapai lebih dari 0.35. Diikuti oleh variabel beta dan temperatur (0.24 dan 0.225), sedangkan variabel lainnya jauh lebih kecil. Hal mengindikasikan kemiripan mekanisme antara dua model (RF dan GBM) dalam mengenali struktur data.

### 3.5 Perbandingan Model

**Table 2.** Perbandingan performa Random Forest dan Gradient Boosting pada prediksi Ekspirasi Radon

Model	R <sup>2</sup> Mean	R <sup>2</sup> Std	RMSE Mean	RMSE Std	MAE Mean	MAE Std
Random Forest	0.422	0.141	0.143	0.017	0.099	0.006
Gradient Boosting	0.473	0.106	0.138	0.018	0.093	0.006

Secara umum tabel 2 memperlihatkan bahwa model GBM memiliki performa yang lebih baik daripada RF. Hal tersebut ditunjukkan oleh nilai R<sup>2</sup>, RMSE, dan MAE. Random Forest memiliki nilai R<sup>2</sup> yang lebih tinggi dan RMSE & MAE yang lebih rendah. Dan variasi nilai R<sup>2</sup>, RMSE, dan MAE dari RF lebih stabil dari GBM yang ditandai dengan nilai standard deviasi yang lebih rendah.

## 4. Kesimpulan

Penelitian ini berhasil memberikan gambaran mengenai potensi paparan radon dari material bangunan lokal di 7 wilayah Jawa tengah dan Jawa Timur. Pengukuran menggunakan RAD7 menunjukkan bahwa konsentrasi radon (Bq m<sup>-3</sup>) dari seluruh sampel berada jauh di bawah batas aman yang ditetapkan oleh IAEA (300 Bq m<sup>-3</sup>), namun terdapat variasi yang nyata antar jenis material dan lokasi, dengan batu bata (BTA) dan semen (SMN) dari wilayah tertentu menunjukkan nilai yang secara signifikan lebih tinggi.

Selain itu, perhitungan laju ekspirasi radon (Bq m<sup>-2</sup> s<sup>-1</sup>) mengungkap bahwa daerah seperti Sukoharjo dan Karanganyar memiliki laju eksalasi lebih tinggi, terutama pada sampel BTA dan SMN. Ini mengindikasikan bahwa selain konsentrasi radon, potensi pelepasan radon dari material juga perlu dipertimbangkan dalam kajian risiko. Laju eksalasi ini juga menjadi indikator penting dalam pengendalian kualitas udara dalam ruang tertutup.



Analisis terhadap bulk density memperlihatkan bahwa hebel memiliki densitas paling rendah, sedangkan pasir paling tinggi. Ini konsisten dengan perbedaan porositas antar material, yang turut berperan dalam difusi gas radon. Sementara itu, pengukuran gross alpha dan beta menunjukkan bahwa hebel memiliki aktivitas radiasi alpha dan beta yang relatif lebih tinggi, yang memperkuat dugaan bahwa kandungan radioaktif alami berbeda antar material.

Selain karakteristik material, variabel lingkungan seperti suhu pengukuran dan lokasi geografis juga memberikan pengaruh terhadap hasil prediksi laju eksalasi radon, walaupun pengaruh yang ditimbulkan sangatlah kecil.

Dalam pemodelan machine learning, hasil evaluasi menunjukkan bahwa gross alfa merupakan variabel paling berpengaruh dalam prediksi, dengan nilai  $R^2$  maksimal sebesar 0.473 pada model GBM, RMSE sebesar 0.138, dan MAE sebesar 0.006. Ini menunjukkan bahwa pendekatan *Machine Learning* mampu menangkap pola kompleks antar variabel.

Secara keseluruhan, penelitian ini menyimpulkan bahwa kombinasi pengukuran konsentrasi dan laju eksalasi radon, dikaitkan dengan parameter fisis dan radioaktif material, dapat memberikan pendekatan yang lebih menyeluruh dalam mengevaluasi risiko paparan radon dari bahan bangunan. Pendekatan machine learning juga terbukti potensial sebagai alat bantu dalam estimasi risiko berbasis data.

Penelitian lanjutan disarankan untuk melibatkan jumlah sampel yang lebih besar serta menambahkan variabel karakteristik material dan lingkungan guna meningkatkan generalisasi model.

## References

- [1] H. N. P. Thu, N. Van Thang *et al.*, “The effects of some soil characteristics on radon emanation and diffusion,” *Journal of environmental radioactivity*, vol. 216, p. 106189, 2020.
- [2] K. F. Al-Shboul, “Unraveling the complex interplay between soil characteristics and radon surface exhalation rates through machine learning models and multivariate analysis,” *Environmental Pollution*, vol. 336, p. 122440, 2023.
- [3] Y. Y. Celen, S. Oncul, B. Narin, and O. Gunay, “Measuring radon concentration and investigation of its effects on lung cancer,” *Journal of Radiation Research and Applied Sciences*, vol. 16, no. 4, p. 100716, 2023.
- [4] A. Shahrokhi, E. Nagy, A. Csordas, J. Somlai, and T. Kovacs, “Distribution of indoor radon concentrations between selected hungarian thermal baths,” *Nukleonika*, vol. 61, 2016.
- [5] A. Grzywa-Celińska, A. Krusiński, J. Mazur, K. Szewczyk, and K. Kozak, “Radon—the element of risk. the impact of radon exposure on human health,” *Toxics*, vol. 8, no. 4, p. 120, 2020.
- [6] T. Dinh Bao, T. Vu, N. T. Tue, T. D. Quy, T. H. Ngo Thi, G. Toth, Z. Homoki, T. Kovacs, and V.-H. Duong, “Machine learning application for radon release prediction from the copper ore mining in sin quyen, lao cai, north vietnam,” *Journal of Radioanalytical and Nuclear Chemistry*, vol. 333, no. 6, pp. 3291–3306, 2024.
- [7] C. de Albuquerque Ferreira, F. J. Dias, B. de Lima Sá, M. R. Monteiro, E. F. de Souza Ladeira, H. P. B. Mendes, R. S. Guimarães, R. L. Guimarães, I. C. B. Lima, and A. X. da Silva, “Implementation of a methodology for analysis of gross alpha and gross beta, as water potability parameters in brazil, and 226ra, 228ra and 210pb for radiological water monitoring,” *Brazilian Journal of Radiation Sciences*, vol. 13, no. 1, pp. e2512–e2512, 2025.
- [8] Q. Sun, J. Hu, J. Jiang, K. Gu, C. Zhu, C. Pan, and W. Yin, “Effect of soil volumetric water content on the co2 diffusion coefficient,” *Sustainability*, vol. 15, no. 16, p. 12637, 2023.
- [9] Y.-j. Ye, W.-h. Wu, S.-y. Feng, C.-h. Huang, and S. Li, “Simultaneous determination of the radon diffusion coefficient and the free radon production rate from compact porous emanation media,” *Building and environment*, vol. 144, pp. 66–71, 2018.

- [10] K. F. Al-Shboul, G. Almasabha, A. Shehadeh, and O. Alshboul, “Exploring the efficacy of machine learning models for predicting soil radon exhalation rates,” *Stochastic Environmental Research and Risk Assessment*, vol. 37, no. 11, pp. 4307–4321, 2023.
- [11] M. Hosoda, S. Tokonami, T. Suzuki, and M. Janik, “Machine learning as a tool for analysing the impact of environmental parameters on the radon exhalation rate from soil,” *Radiation Measurements*, vol. 138, p. 106402, 2020.